WORKSHEET PRAKTIKUM 3
TEKNOLOGI BIG DATA

Perumusan Masalah dan Pemilihan Metode Analitik

A. DESKRIPSI PRAKTIKUM

Pada Worksheet 1 telah mengenali dan mengeksplorasi dataset yang akan digunakan. Selanjutnya, pada Worksheet 2 menentukan topik/permasalahan dan menggambarkan bagaimana data dapat mengalir dalam suatu sistem Big Data.

Pada praktikum ini, kalian akan menentukan permasalahan yang lebih spesifik dan metode analitik yang sesuai untuk menyelesaikan permasalahan tersebut.

Fokus praktikum adalah memahami hubungan antara:
Permasalahan → Tujuan Analisis → Pertanyaan Analitik → Jenis Analitik → Metode Analitik

Pada tahap ini, kalian belum perlu melakukan implementasi atau coding model. Rancangan teknis dan tahapan pengolahan data secara lebih detail akan dilakukan pada Worksheet 4.

B. TUJUAN PRAKTIKUM

Setelah menyelesaikan worksheet ini, mahasiswa diharapkan mampu:

1. Merumuskan permasalahan berdasarkan dataset dan topik yang telah dipilih.
2. Menentukan tujuan analisis yang ingin dicapai.
3. Menyusun pertanyaan analitik yang dapat dijawab menggunakan data.
4. Menentukan jenis analitik yang sesuai dengan permasalahan.
5. Memilih metode analitik yang sesuai.
6. Menjelaskan alasan pemilihan metode analitik.
7. Mengidentifikasi target atau hasil yang ingin diperoleh dari analisis.

C. KETERKAITAN DENGAN WORKSHEET SEBELUMNYA

Worksheet	Fokus	Pertanyaan Utama
Worksheet 1	Mengenali Data	Data apa yang saya punya?
Worksheet 2	Menentukan Topik & Arsitektur	Masalah apa yang ingin saya selesaikan dan bagaimana data mengalir?
Worksheet 3	Perumusan Masalah & Metode	Apa yang ingin saya analisis dan metode apa yang sesuai?

D. IDENTITAS PROYEK

Nama Kelompok	Kelompok 11
Anggota Kelompok	●Misael Feodora Pranata Dauhan (J0403241145) ●Gerry Dimasarya (J0403241042) ●Aryo Ristiawan Machfudz (J0403241005)

	●Muhammad Zahran Rabbani (J0403241077)
Dataset	An Online Shop Business
Sumber Dataset	Kaggle
Domain/Bidang	E-Commerce
Topik Proyek	Sistem Informasi Monitor Batch & Agregasi Stok (SIMBA)

E. LANGKAH 1 MEMAHAMI KEMBALI DATA

1. Apa karakteristik utama dataset yang digunakan?

Dataset merupakan data terstruktur berbentuk format CSV dengan ukuran masif yang berisi lebih dari 536.350 baris rekaman historis transaksi *e-commerce*. Data ini mencatat logistik transaksi berbasis waktu (*time-series*).

2. Informasi apa yang dapat diperoleh dari dataset?

Informasi riwayat pesanan (nomor transaksi, kuantitas, harga) beserta waktu terjadinya transaksi harian/bulanan yang sangat ideal untuk analisis agregasi dan tren pergerakan stok barang.

3. Permasalahan apa yang berpotensi dianalisis berdasarkan dataset tersebut?

No.	Alternatif Permasalahan	Data yang Mendukung
1	Tidak adanya prediksi waktu pasti terkait kapan terjadinya lonjakan pesanan pelanggan secara periodik.	`Date`, `TransactionNo`, `Quantity`
2	Sulitnya mendeteksi performa tiap produk secara individual apakah sedang mengalami penurunan atau pelonjakan minat beli.	`ProductName`, `Date`, `Quantity`

F. LANGKAH 2 MERUMUSKAN MASALAH

Rumusan Masalah

Permasalahan utama yang dihadapi dalam operasional bisnis e-commerce saat ini adalah ketiadaan prediksi yang akurat terkait jadwal lonjakan pesanan pelanggan berdasarkan periode waktu tertentu (hari atau bulan), yang mengakibatkan ketidakefisienan manajemen dalam merencanakan ketersediaan alokasi stok barang.

Permasalahan utama:
Tidak adanya prediksi akurat terkait tren lonjakan transaksi berdasarkan hari atau bulan tertentu, yang menyulitkan sistem dalam melakukan perencanaan alokasi stok barang secara optimal.

Pihak yang Berkepentingan

Siapa yang membutuhkan informasi atau solusi dari permasalahan tersebut?
Pengguna (*User*) dan pemangku kepentingan (*Stakeholder*) operasional bisnis e-commerce.

Mengapa permasalahan tersebut penting untuk diselesaikan?

Agar manajemen memiliki landasan utama (basis data prediksi) dalam mengambil keputusan strategis terkait manajemen inventaris, sehingga menghindari kekosongan gudang saat pesanan melonjak.

G. LANGKAH 3 MENENTUKAN TUJUAN ANALISIS

Tujuan Utama

Memantau lonjakan transaksi berdasarkan hari atau bulan tertentu untuk membantu perencanaan stok barang.

Tujuan Khusus

No.	Tujuan Analisis
1	Mengidentifikasi tren dan metrik penjualan e-commerce berdasarkan data historis transaksi.
2	Memprediksi potensi lonjakan permintaan produk menggunakan analisis *time series*.
3	Mengklasifikasikan pola pergerakan inventaris produk ke dalam kategori stabil, menurun, atau melonjak.

Gunakan kata kerja yang jelas, misalnya:

- memprediksi;
- mengklasifikasikan;
- mengelompokkan;
- mengidentifikasi;
- menemukan;
- membandingkan;
- menganalisis.

H. LANGKAH 4 MENENTUKAN PERTANYAAN ANALITIK

No.	Pertanyaan Analitik

1	Pada hari atau bulan apa saja transaksi penjualan diperkirakan mengalami lonjakan?
2	Produk apa saja (top produk) yang berpotensi mengalami lonjakan permintaan tertinggi?
3	Termasuk ke dalam kelas/kategori pergerakan apakah setiap produk tersebut (stabil, menurun, atau melonjak)?

Contoh
Permasalahan:
Perusahaan ingin mengurangi jumlah pelanggan yang berhenti menggunakan layanan.
Tujuan:
Memprediksi pelanggan yang berpotensi berhenti.
Pertanyaan analitik:

1. Faktor apa yang berkaitan dengan pelanggan yang berhenti?
2. Pelanggan mana yang memiliki karakteristik berisiko churn?
3. Seberapa baik data historis dapat digunakan untuk memprediksi churn?

I. LANGKAH 5 MENENTUKAN JENIS ANALITIK

Jenis Analitik	Digunakan Ketika	Contoh Pertanyaan
Descriptive Analytics	Ingin mengetahui kondisi/pola yang terjadi	Apa yang terjadi?
Classification	Ingin memprediksi kategori/kelas	Termasuk kelas apa?
Regression / Prediction	Ingin memprediksi nilai numerik	Berapa nilai yang akan terjadi?
Clustering	Ingin mengelompokkan data berdasarkan kemiripan	Kelompok apa yang terbentuk?
Association Rules	Ingin menemukan hubungan antar-item	Item apa yang sering muncul bersama?

Hasil Pemilihan

Komponen	Jawaban
Jenis analitik yang dipilih	Prediction (*Time Series Forecasting*) dan Classification.
Tujuan penggunaan	Ingin memprediksi potensi lonjakan permintaan produk di waktu mendatang dan mengklasifikasikan pola pergerakan inventarisnya (stabil, menurun, atau melonjak).
Output yang diharapkan	Visualisasi *dashboard* interaktif pada Power BI yang menampilkan metrik utama berupa monitor lonjakan transaksi, tren penjualan, *top produk*, serta rekomendasi perencanaan stok barang untuk *stakeholder*.

J. LANGKAH 6 MEMILIH METODE ANALITIK

Pilihan Metode

Jenis Analitik	Contoh Metode
Classification	Decision Tree, Naive Bayes, SVM
Regression	Linear Regression, Decision Tree Regression
Clustering	K-Means
Association Rules	Apriori / Association Rules
Descriptive Analytics	Aggregation, Summary Statistics, Comparative Analysis

Rancangan Metode

Komponen	Jawaban
Jenis analitik	Prediction (Regression) dan Classification (Analitik Lanjutan).
Metode yang dipilih	*Time Series Analysis* dan *Trend Detection* menggunakan Apache MADlib (*In-Database Analytics*).
Input/Data yang digunakan	Tabel hasil agregasi penjualan (waktu dan kuantitas transaksi dari CSV) yang telah dibersihkan oleh PySpark di dalam PostgreSQL.
Target/Output	Visualisasi *dashboard* interaktif pada Power BI yang menampilkan metrik utama berupa monitor lonjakan transaksi, tren penjualan, top produk, serta rekomendasi perencanaan stok barang untuk *stakeholder*
Alasan pemilihan metode	MADlib berjalan langsung di dalam basis data (*in-database*), sehingga menghemat memori (RAM/CPU lokal) karena tidak perlu mengekspor lebih dari 500 ribu baris data masif ke luar sistem, dan hasilnya dapat langsung ditarik ke Power BI.

K. LANGKAH 7 MEMBANDINGKAN ALTERNATIF METODE

Komponen	Metode Utama	Metode Alternatif
Nama metode	Time Series Analysis dan Trend Detection menggunakan Apache MADlib	Random Forest Regression
Kelebihan untuk permasalahan ini	Dapat menganalisis pola transaksi berdasarkan waktu dan memprediksi tren atau potensi lonjakan transaksi.	Dapat digunakan untuk memprediksi nilai numerik berdasarkan berbagai variabel

Kekurangan untuk permasalahan ini	Membutuhkan data historis yang memiliki pola waktu yang cukup konsisten dan proses agregasi berdasarkan waktu sebelum dilakukan forecasting	Kurang berfokus pada pola temporal dan seasonality secara langsung
Alasan dipilih/tidak dipilih	karena permasalahan utama berfokus pada prediksi tren dan lonjakan transaksi berdasarkan waktu	Tidak dipilih karena fokus utama permasalahan adalah pola transaksi berdasarkan waktu, sehingga metode Time Series lebih sesuai

Pertanyaan Analisis

Mengapa kelompok memilih metode utama tersebut dibandingkan metode alternatif?

Kelompok memilih Time Series Analysis dan Trend Detection menggunakan Apache MADlib karena permasalahan yang ingin diselesaikan berfokus pada prediksi tren dan lonjakan transaksi berdasarkan waktu, yaitu hari atau bulan tertentu. Metode Time Series lebih sesuai karena dapat menganalisis pola historis transaksi dan menggunakannya untuk memperkirakan kondisi pada periode berikutnya.

L. LANGKAH 8 MENENTUKAN TARGET HASIL

1. Hasil apa yang ingin diperoleh?

Hasil yang ingin diperoleh adalah prediksi tren dan potensi lonjakan transaksi berdasarkan hari atau bulan, identifikasi produk yang berpotensi mengalami peningkatan permintaan, serta klasifikasi pola pergerakan produk menjadi stabil, menurun, atau melonjak. Hasil tersebut kemudian ditampilkan dalam dashboard Power BI untuk membantu perencanaan alokasi stok barang.

2. Dalam bentuk apa hasil tersebut?

- ☑ Kategori/kelas
- ☑ Nilai numerik
- ☐ Kelompok/cluster
- ☐ Pola/hubungan antar-item
- ☑ Informasi deskriptif
- ☑ Lainnya: Visualisasi dashboard

3. Bagaimana hasil tersebut dapat membantu pengambilan keputusan?

Hasil analisis dapat membantu stakeholder dan tim operasional dalam menentukan kebutuhan stok berdasarkan prediksi permintaan, terutama pada periode yang diperkirakan mengalami lonjakan transaksi. Informasi mengenai tren dan klasifikasi pergerakan produk dapat digunakan untuk

menentukan produk yang perlu diprioritaskan dalam pengadaan dan alokasi stok.

M. RINGKASAN RANCANGAN PROYEK

Lengkapi alur berikut berdasarkan hasil diskusi kelompok.

Dataset
↓
Permasalahan
↓
Tujuan Analisis
↓
Pertanyaan Analitik
↓
Jenis Analitik
↓
Metode Analitik
↓
Target/Output

Tahapan	**Hasil Kelompok**
Dataset	Kaggle”"An Online Shop Business"
Permasalahan	Tidak adanya prediksi akurat terkait tren lonjakan transaksi berdasarkan hari atau bulan tertentu, yang menyulitkan sistem dalam melakukan perencanaan alokasi stok barang secara optimal.
Tujuan Analisis	Memantau lonjakan transaksi berdasarkan hari atau bulan tertentu untuk membantu perencanaan stok barang.
Pertanyaan Analitik	1. Pada hari atau bulan apa saja transaksi penjualan diperkirakan mengalami lonjakan? 2. Produk apa saja (*top produk*) yang berpotensi mengalami lonjakan permintaan tertinggi? 3. Termasuk ke dalam kelas/kategori pergerakan apakah setiap produk tersebut (stabil, menurun, atau melonjak)?
Jenis Analitik	*Prediction* (*Time Series Forecasting*) dan *Classification*.
Metode Analitik	*Time Series Analysis* dan *Trend Detection* menggunakan Apache MADlib (*In-Database Analytics*).
Target/Output	Visualisasi *dashboard* interaktif pada Power BI yang menampilkan metrik utama berupa monitor lonjakan transaksi, tren penjualan, *top produk*, serta rekomendasi perencanaan stok barang untuk *stakeholder*.

N. DISKUSI KELOMPOK

1. Apakah permasalahan yang dipilih benar-benar dapat dijawab menggunakan dataset yang tersedia?

Ya, dapat dijawab sepenuhnya. Dataset *"An Online Shop Business"* memiliki lebih dari 500.000 baris data terstruktur yang memuat variabel histori transaksi seperti tanggal transaksi (Date), nomor pesanan (TransactionNo), kuantitas produk (Quantity), dan nama produk (ProductName). Atribut *time-series* dan kuantitas ini sangat memadai untuk diagregasikan harian maupun bulanan untuk memodelkan tren lonjakan transaksi dan pola pergerakan stok barang.

2. Apakah metode yang dipilih sesuai dengan jenis data dan tujuan analisis?

Sangat sesuai. Dataset bersifat terstruktur dan disimpan di dalam basis data relasional PostgreSQL. Penggunaan Apache MADlib (*In-Database Analytics*) untuk *Time Series Analysis* dan *Trend Detection* memungkinkan proses analitik dieksekusi langsung di dalam basis data menggunakan kueri SQL. Pendekatan ini selaras dengan tujuan analisis untuk memprediksi lonjakan pesanan tanpa perlu memindahkan data masif ke luar sistem, sehingga efisien dari sisi pemrosesan komputasi.

3. Apa risiko jika kelompok memilih metode analitik yang tidak sesuai?

1. Risiko Performa & Pemborosan *Resource* (*Bottleneck*): Jika menggunakan metode analitik eksternal biasa (ekspor data masif ke *script* luar), akan terjadi pemborosan alokasi RAM dan CPU yang berisiko memicu kecelakaan sistem (*Out of Memory* / OOM).
2. Risiko Ketidakakuratan Keputusan Bisnis: Jika hanya menggunakan agregasi deskriptif sederhana tanpa pemodelan *time-series*, sistem tidak dapat menangkap pola fluktuasi/musiman (*seasonality*) lonjakan transaksi. Akibatnya, rekomendasi stok menjadi tidak akurat yang berpotensi menyebabkan kehabisan barang (*stockout*) saat pesanan melonjak atau penumpukan inventaris (*overstock*).

O. OUTPUT PRAKTIKUM

Setiap kelompok mengumpulkan 1 dokumen PDF yang berisi:

1. Identitas proyek.
2. Permasalahan utama.
3. Tujuan analisis.
4. Pertanyaan analitik.
5. Jenis analitik.
6. Metode analitik yang dipilih.
7. Alasan pemilihan metode.
8. Metode alternatif dan perbandingannya.
9. Target/output analisis.
10. Ringkasan rancangan proyek.

Ketentuan :

Pada Worksheet 3 belum diwajibkan melakukan implementasi/coding model. Fokus penilaian adalah kemampuan kelompok dalam merumuskan masalah dan memberikan argumentasi yang logis dalam memilih metode analitik.

Q. RUBRIK PENILAIAN

Komponen Penilaian	Bobot
Perumusan masalah	20%
Tujuan dan pertanyaan analitik	20%
Ketepatan jenis analitik	15%
Pemilihan metode analitik	20%
Argumentasi dan perbandingan metode	15%
Target/output dan keterkaitan dengan masalah	10%
Total	**100%**

HASIL AKHIR WORKSHEET 3

“Kami memiliki data 'An Online Shop Business' (riwayat transaksi e-commerce >500.000 baris) , ingin menyelesaikan permasalahan tidak adanya prediksi akurat terkait tren lonjakan transaksi harian/bulanan yang menyulitkan alokasi stok barang, dengan tujuan memantau lonjakan transaksi berdasarkan hari atau bulan tertentu untuk membantu perencanaan stok barang. Untuk menjawab permasalahan tersebut, kami menggunakan jenis analitik _____ dan metode Prediction (Time Series Forecasting) dan Classification dan metode Time Series Analysis serta Trend Detection menggunakan Apache MADlib (In-Database Analytics) karena dapat mengeksekusi pemodelan analitik secara langsung di dalam database PostgreSQL sehingga sangat menghemat alokasi RAM dan CPU lokal. Hasil yang diharapkan adalah dashboard interaktif pada Power BI yang dapat digunakan untuk membantu stakeholder dan tim operasional bisnis dalam mengambil keputusan strategis terkait manajemen inventaris dan alokasi stok barang .”